



西安电子科技大学  
XIDIAN UNIVERSITY



IPIL  
智能感知与图像理解

# 最优化理论

## 第二章 最优化问题的数学基础I

人工智能学院  
智能感知与图像理解实验室



## 第二章 最优化问题的数学基础 I

1

向量知识与范数理论

2

二次型与正定矩阵

3

方向导数与梯度

4

Hesse矩阵及泰勒展式





## 向量的内积

设在 $n$ 维线性空间 $R^n$ 中,  $\vec{a} = (a_1, a_2, \dots, a_n)^T \in R^n$ ,

$\vec{b} = (b_1, b_2, \dots, b_n)^T \in R^n$ , 则

$a_1b_1 + a_2b_2 + \dots + a_nb_n$ 称为向量 $\vec{a}$ 与 $\vec{b}$ 的内积,

$$\text{记作 } [\vec{a}, \vec{b}] = \vec{a}^T \vec{b} = (a_1, a_2, \dots, a_n) \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{pmatrix}$$





## 内积的性质

- i)  $[\alpha, \beta] = [\beta, \alpha]$  (对称性) ;
- ii)  $[\alpha + \beta, \gamma] = [\alpha, \gamma] + [\beta, \gamma]$ ,  
 $[k\alpha, \beta] = k[\alpha, \beta]$  (线性性) ;
- iii)  $[\alpha, \alpha] \geq 0$  当且仅当  $\alpha = \bar{0}$  时,  
 $[\alpha, \alpha] = 0$  (正定性) ;





## 向量性质


向量的长  $\|\alpha\| = \sqrt{[\alpha, \alpha]}$

单位向量  $\|\alpha\| = 1$

向量的夹角  $\langle \alpha, \beta \rangle = \arccos \frac{[\alpha, \beta]}{\|\alpha\| \cdot \|\beta\|}$

$$0 \leq \langle \alpha, \beta \rangle \leq \pi$$

向量的正交  $\langle \alpha, \beta \rangle = \frac{\pi}{2} \Leftrightarrow [\alpha, \beta] = 0$





## 范数

定义：若函数  $\|\cdot\|: \mathbb{R}^n \rightarrow \mathbb{R}$  满足：

(1) 正定性：  $\forall x \in \mathbb{R}^n, \|x\| \geq 0, \|x\| = 0 \Leftrightarrow x = 0$ ;

(2) 三角不等式：  $\forall x, y \in \mathbb{R}^n, \|x + y\| \leq \|x\| + \|y\|$ ;

(3) 齐次性：  $\forall x \in \mathbb{R}^n, \forall \alpha \in \mathbb{R}, \|\alpha x\| = |\alpha| \|x\|$ .

则  $\|\cdot\|$  称为  $\mathbb{R}^n$  上的 **范数**





## 范数

常见范数:  $x = (x_1, x_2, \dots, x_n)^T \in R^n$

1-范数  $\|x\|_1 = \sum_{i=1}^n |x_i|;$

表示向量x中非零元素的绝对值之和

2-范数  $\|x\|_2 = (\sum_{i=1}^n x_i^2)^{1/2};$

表示向量元素的平方和再开平方。

$\infty$ -范数  $\|x\|_\infty = \max_i |x_i|;$

用来度量向量元素的最大值

$p$ -范数  $\|x\|_p = (\sum_{i=1}^n x_i^p)^{1/p}, 1 \leq p < +\infty;$

向量元素绝对值的p次方和的1/p次幂





## 范数举例

例1:对于向量 $x=(1,-2,3)^T$ , 尝试计算 $L_1, L_2, L_3, L_\infty$

对向量 $x=(1,-2,3)^T$ , 有

$$\|x\|_1 = |1| + |-2| + |3| = 6,$$

$$\|x\|_2 = \sqrt{1^2 + (-2)^2 + 3^2} = \sqrt{14} \approx 3.74,$$

$$\|x\|_3 = \sqrt[3]{1^3 + (-2)^3 + 3^3} = \sqrt[3]{36} \approx 3.30,$$

$$\|x\|_\infty = \max\{|1|, |-2|, |3|\} = 3$$







西安电子科技大学  
XIDIAN UNIVERSITY

# 二次型与正定矩阵

## 二次型

$n$ 维二次函数:

$$\begin{aligned} f(x_1, x_2, \dots, x_n) &= a_{11}x_1^2 + a_{12}x_1x_2 + \dots + a_{1n}x_1x_n + \\ &\quad a_{21}x_2x_1 + a_{22}x_2^2 + \dots + a_{2n}x_2x_n + \\ &\quad \dots + \\ &\quad a_{n1}x_nx_1 + a_{n2}x_nx_2 + \dots + a_{nn}x_n^2 \\ &= \sum_{i=1}^n \sum_{j=1}^n a_{ij}x_ix_j \end{aligned}$$



智能感知与图像理解教育部重点实验室

KEY LABORATORY OF INTELLIGENT PERCEPTION  
AND IMAGE UNDERSTANDING OF MINISTRY OF EDUCATION






西安电子科技大学  
XIDIAN UNIVERSITY

# 二次型与正定矩阵

## 为什么要通过矩阵来研究二次型？




智能感知与图像理解教育部重点实验室  
KEY LABORATORY OF INTELLIGENT PERCEPTION  
AND IMAGE UNDERSTANDING OF MINISTRY OF EDUCATION





## 为什么要通过矩阵来研究二次型？





## 二次型

用矩阵可表示为:

$$f(x_1, x_2, \dots, x_n) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j = [x_1, x_2, \dots, x_n] A \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$
$$= x^T A x$$

其中二次型的系数矩阵A为对称阵,  $A = A^T$

其元素  $a_{ij} = a_{ji} (i \neq j)$  是二次型  $x_i x_j$  项系数的一半

$a_{ii}$  是二次型  $x_i^2$  的系数

因此二次型和它的系数矩阵A是相互唯一决定的





## 二次型及其系数矩阵

$$\left. \begin{aligned} [x \quad y] \begin{bmatrix} a & b \\ b & c \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} &= 1 \\ X &= \begin{bmatrix} x \\ y \end{bmatrix} \\ A &= \begin{bmatrix} a & b \\ b & c \end{bmatrix} \end{aligned} \right\} \Rightarrow X^T A X$$


对称阵  $\Leftrightarrow$  二次型






## 一个简单的二次型

$$\begin{bmatrix} x & y \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = 1$$






## 稍作改变





## 稍作改变








## 改变副对角元素

$$\begin{bmatrix} x & y \end{bmatrix} \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = 1$$





**例2** 用矩阵符号表示下列二次型：

$$f(x_1, x_2, x_3) = x_1^2 + 4x_1x_2 + 4x_2^2 + 2x_1x_3 + x_3^2 + 4x_2x_3$$

解：

$$f(x_1, x_2, x_3) = (x_1, x_2, x_3) \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$





**例3.** 用矩阵符号表示下列二次型：

$$f(x_1, x_2, x_3) = x_1^2 + x_2^2 - 7x_3^2 - 2x_1x_2 - 4x_1x_3 - 4x_2x_3$$

解：

$$f(x_1, x_2, x_3) = (x_1, x_2, x_3) \begin{bmatrix} 1 & -1 & -2 \\ -1 & 1 & -2 \\ -2 & -2 & -7 \end{bmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$





## 正定矩阵

定义：如果二次型

$$f(x_1, x_2, \dots, x_n) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j = X^T A X$$

对于任意一组不全为零的数  $x_1, x_2, \dots, x_n$ ，恒有

$$f(x_1, x_2, \dots, x_n) = X^T A X > 0$$

则称  $f(x_1, x_2, \dots, x_n)$  正定，其  $A$  为正定矩阵

类似的，

若有  $f(x_1, x_2, \dots, x_n) = X^T A X \geq 0$ ，则  $A$  为半正定矩阵

若有  $f(x_1, x_2, \dots, x_n) = X^T A X \leq 0$ ，则  $A$  为半负定矩阵





## 正定矩阵的判定

判定定理1:  $A$  正定的充要条件为  $A$  的特征值都大于零

判定定理2:  $A$  正定的充要条件为  $A$  的所有顺序主子式都大于零

设  $A$  为  $n \times n$  阶矩阵, 子式

$$D_i = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1i} \\ a_{21} & a_{22} & \cdots & a_{2i} \\ \vdots & \vdots & & \vdots \\ a_{i1} & a_{i2} & \cdots & a_{ii} \end{vmatrix} (i = 1, 2, \dots, n)$$

称为  $A$  的  $i$  阶顺序主子式。





## 例4. 用顺序主子式判断矩阵是否正定

判断矩阵  $A = \begin{bmatrix} 4 & 2 & 1 \\ 2 & 3 & 0 \\ 1 & 0 & 2 \end{bmatrix}$  是否正定。

$$\text{解1: } 4 > 0, \begin{vmatrix} 4 & 2 \\ 2 & 3 \end{vmatrix} = 8 > 0, \begin{vmatrix} 4 & 2 & 1 \\ 2 & 3 & 0 \\ 1 & 0 & 2 \end{vmatrix} = 13 > 0$$

$A$  是正定的





## 例5. 用特征值判断矩阵是否正定

判断矩阵  $A = \begin{bmatrix} 4 & 2 & 1 \\ 2 & 3 & 0 \\ 1 & 0 & 2 \end{bmatrix}$  是否正定。

解2:  $|\lambda I - A| = 0$

$$\begin{vmatrix} \lambda - 4 & 2 & 1 \\ 2 & \lambda - 3 & 0 \\ 1 & 0 & \lambda - 2 \end{vmatrix} = (\lambda - 4)(\lambda - 3)(\lambda - 2) - (\lambda - 3) - 4(\lambda - 2) = 0$$

$$\lambda_1 = 1, \lambda_2 = 2.28, \lambda_3 = 5.73$$

$A$  是正定的





## 例6. 判断下列二次型是否正定

$$1) f(x_1, x_2, x_3, x_4) = x_1^2 + 3x_2^2 + 9x_3^2 + 19x_4^2 - 2x_1x_2 + 4x_1x_3 - 6x_2x_4 - 12x_3x_4 + 2x_1x_4$$

解:

$$A = \begin{pmatrix} 1 & -1 & 2 & 1 \\ -1 & 3 & 0 & -3 \\ 2 & 0 & 9 & -6 \\ 1 & -3 & -6 & 19 \end{pmatrix} \quad |A_1| = 1 > 0 \quad |A_2| = \begin{vmatrix} 1 & -1 \\ -1 & 3 \end{vmatrix} = 3 + 1 = 4 > 0$$

$$|A_3| = \begin{vmatrix} 1 & -1 & 2 \\ -1 & 3 & 0 \\ 2 & 0 & 9 \end{vmatrix} = 27 + (-1) \times [0 - (-9)] + 2 \times (0 - 6) = 6 > 0$$







# 二次型与正定矩阵

$$\begin{aligned} |A_4| &= \begin{vmatrix} 1 & -1 & 2 & 1 \\ -1 & 3 & 0 & -3 \\ 2 & 0 & 9 & -6 \\ 1 & -3 & -6 & 19 \end{vmatrix} = 1 \times \begin{vmatrix} 3 & 0 & -3 \\ 0 & 9 & -6 \\ -3 & -6 & 19 \end{vmatrix} + (-1) \times \begin{vmatrix} 1 & 0 & -3 \\ 2 & 9 & -6 \\ 1 & -6 & 19 \end{vmatrix} \\ &+ 2 \times \begin{vmatrix} -1 & 3 & -3 \\ 2 & 0 & -6 \\ 1 & -3 & 19 \end{vmatrix} + 1 \times \begin{vmatrix} -1 & 3 & 0 \\ 2 & 0 & 9 \\ 1 & -3 & -6 \end{vmatrix} = 24 > 0 \end{aligned}$$

该二次型是正定的





**例6.** 判断下列二次型是否正定

$$f(x_1, x_2, x_3) = 5x_1^2 + x_2^2 + 5x_3^2 + 4x_1x_2 - 8x_1x_3 - 4x_2x_3$$

解:

$$A = \begin{pmatrix} 5 & 2 & -4 \\ 2 & 1 & -2 \\ -4 & -2 & 5 \end{pmatrix}$$

$$|A_1| = 5 > 0$$

$$|A_2| = \begin{vmatrix} 5 & 2 \\ 2 & 1 \end{vmatrix} = 1 > 0$$

$$|A_3| = \begin{vmatrix} 5 & 2 & -4 \\ 2 & 1 & -2 \\ -4 & -2 & 5 \end{vmatrix} = 5 \times (1 \times 5 - 4) + 2 [(-2) \times (-4) - 2 \times 5]$$

$$-4 [2 \times 2 - 1 \times (-4)] = 1 > 0$$

该二次型是正定的






# 方向导数与梯度

## 导数


函数曲线上的切线斜率；函数在某点的变化率。



$$f'(x_0) = \lim_{\Delta x \rightarrow 0} \frac{\Delta y}{\Delta x} = \lim_{\Delta x \rightarrow 0} \frac{f(x_0 + \Delta x) - f(x_0)}{\Delta x}$$

## 偏导数

多元函数在坐标轴正方向上的变化率



$$f_x(x, y) = \lim_{\Delta x \rightarrow 0} \frac{f(x + \Delta x, y) - f(x, y)}{\Delta x}$$

- 偏导数  $f_x(x, y)$  就是曲面被平面  $y = y_0$  所截得的曲线在点  $M_0$  处的切线  $M_0T_x$  对  $x$  轴的斜率

- 偏导数  $f_y(x, y)$  就是曲面被平面  $x = x_0$  所截得的曲线在点  $M_0$  处的切线  $M_0T_y$  对  $y$  轴的斜率





# 方向导数




# 方向导数与梯度

Directional Derivatives : Along the Axes...

方向导数用于研究函数沿各个不同方向时函数的变化率，是标量。

$$\frac{\partial f(x, y)}{\partial y}$$

$$\frac{\partial f(x, y)}{\partial x}$$



$$\frac{\partial f}{\partial l} \big|_{(x_0, y_0)} = \lim_{\substack{\Delta x \rightarrow 0 \\ \Delta y \rightarrow 0}} \frac{f(x_0 + \Delta x, y_0 + \Delta y) - f(x_0, y_0)}{\sqrt{\Delta x^2 + \Delta y^2}}$$

$$\frac{\partial f}{\partial l} \big|_{(x_0, y_0)} = f'_x(x_0, y_0) \cos \alpha + f'_y(x_0, y_0) \cos \beta$$





## 方向导数

定义：设  $f: R^n \rightarrow R^1$  在点  $x_0$  处可微， $P$  是固定不变的非零向量， $e$  是方向  $P$  上的单位向量，则称极限

$$\frac{\partial f(x_0)}{\partial p} = \lim_{t \rightarrow 0^+} \frac{f(x_0 + te) - f(x_0)}{t}$$

为函数  $f(x)$  在点  $x_0$  处沿  $P$  方向的方向导数，记为  $\frac{\partial f(x_0)}{\partial p}$





## 上升方向与下降方向

定义：设  $f: R^n \rightarrow R^1$  是连续函数， $x_0 \in R^n, P \in R^n$ , 且  $P \neq 0$ ,  
若存在  $\delta > 0$ , 当  $t \in (0, \delta)$  时都有  $f(x_0 + tP) < f(x_0)$ , 则称  $P$  为  $f$  在  $x_0$   
处的下降方向。若  $f(x_0 + tP) > f(x_0)$ , 则称  $P$  为  $f$  在  $x_0$  处的上升方向。

由上两个定义可以得出如下结论：

若  $\frac{\partial f(x_0)}{\partial P} < 0$ , 则  $f(x)$  在  $x_0$  处沿  $P$  方向是下降的；

若  $\frac{\partial f(x_0)}{\partial P} > 0$ , 则  $f(x)$  在  $x_0$  处沿  $P$  方向是上升的；





## 梯度

定义：以函数 $f(x)$ 的 $n$ 个偏导数为分量的向量称为 $f(x)$ 在点 $x$ 处的梯度  
记为

$$\nabla f(x) = \left[ \frac{\partial f(x)}{\partial x_1}, \frac{\partial f(x)}{\partial x_2}, \dots, \frac{\partial f(x)}{\partial x_n} \right]^T$$

梯度也可以称为 $f(x)$ 关于向量 $x$ 的一阶导数。







## 梯度与方向导数之间的关系

定理：设  $f: R^n \rightarrow R^1$  在  $x_0$  处可微，则

$$\frac{\partial f(x_0)}{\partial P} = \nabla f(x_0)^T e$$

其中  $e$  是  $P$  方向上的单位向量。

$$\begin{aligned} \left| \frac{\partial f(x_0)}{\partial P} \right| &= \left| \nabla f(x_0)^T e \right| \\ &= \left| \nabla f(x_0) \right| \cdot \left| \cos(\nabla f(x_0), e) \right| \leq \left| \nabla f(x_0) \right| \end{aligned}$$







## 梯度与方向导数之间的关系

推论：

1. 若  $\nabla f(x_0)^T P < 0$ , 则P的方向是函数  $f(x)$  在  $x_0$  处的下降方向;
2. 若  $\nabla f(x_0)^T P > 0$ , 则P的方向是函数  $f(x)$  在  $x_0$  处的上升方向;

证明1:  $\nabla f(x_0)^T P < 0, \nabla f(x_0)^T e = \nabla f(x_0)^T \frac{P}{\|P\|}$

$$\Rightarrow \nabla f(x_0)^T e < 0$$

由定理  $\frac{\partial f(x_0)}{\partial P} = \nabla f(x_0)^T e$

$$\Rightarrow \frac{\partial f(x_0)}{\partial P} < 0$$


得证





## 关于梯度与方向导数的结论

1. 梯度方向是函数值的最速上升方向；
2. 函数在与其梯度正交的方向上变化率为零；
3. 函数在与其梯度成锐角的方向上是上升的，**变化率为0的方向**而在与其梯度成钝角的方向上是下降的；
4. 梯度反方向是函数值的最速下降方向。





## 例7.

试求目标函数  $f(x) = x_1^2 + x_2^2 + 1$  在点  $x_0 = [0, 3]^T$  处的最速下降方向，并求沿这个方向移动一个单位后新点的目标函数值。

$$\text{解: } \frac{\partial f}{\partial x_1} = 2x_1, \frac{\partial f}{\partial x_2} = 2x_2$$

最速下降方向是

$$-\nabla f(x_0) = -\begin{bmatrix} 2x_1 \\ 2x_2 \end{bmatrix}_{x_1=0, x_2=3} = \begin{bmatrix} 0 \\ -6 \end{bmatrix}$$

此方向的单位向量为

$$e = \frac{-\nabla f(x_0)}{\|-\nabla f(x_0)\|} = \begin{bmatrix} 0 \\ -1 \end{bmatrix}$$

(接下页)





## 例题

试求目标函数  $f(\mathbf{x}) = x_1^2 + x_2^2 + 1$  在点  $\mathbf{x}_0 = [0, 3]^T$  处的最速下降方向，并求沿这个方向移动一个单位后新点的目标函数值。

(接上页)

故新点是

$$\mathbf{x}_1 = \mathbf{x}_0 + \mathbf{e} = \begin{bmatrix} 0 \\ 3 \end{bmatrix} + \begin{bmatrix} 0 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}$$

对应目标函数值为  $f(\mathbf{x}_1) = 0^2 + 2^2 + 1 = 5$

原函数值为  $f(\mathbf{x}_0) = 0^2 + 3^2 + 1 = 10$





## Hesse矩阵

定义:  $f: R^n \rightarrow R^1$ ,  $x_0 \in R^n$ , 如果 $f$ 在点 $x_0$ 处对于自变量 $x$ 的各分量的二阶偏导数

$$\frac{\partial^2 f(x_0)}{\partial x_i \partial x_j}, (i, j = 1, 2, \dots, n)$$

都存在, 则称函数 $f$ 在点 $x_0$ 处二阶可到, 并且称矩阵

$$\nabla^2 f(x_0) = \begin{bmatrix} \frac{\partial^2 f(x_0)}{\partial x_1^2} & \frac{\partial^2 f(x_0)}{\partial x_1 \partial x_2} & \dots & \frac{\partial^2 f(x_0)}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f(x_0)}{\partial x_2 \partial x_1} & \frac{\partial^2 f(x_0)}{\partial x_2^2} & \dots & \frac{\partial^2 f(x_0)}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f(x_0)}{\partial x_n \partial x_1} & \frac{\partial^2 f(x_0)}{\partial x_n \partial x_2} & \dots & \frac{\partial^2 f(x_0)}{\partial x_n^2} \end{bmatrix}$$

是 $f$ 在点 $x_0$ 处的Hesse矩阵。





## 例8.

求目标函数 $f(x)=x_1^4 + 2x_2^3 + 3x_3^2 - x_1^2x_2 + 4x_2x_3 - x_1x_3^2$ 的梯度和Hesse矩阵

解:

$$\frac{\partial f}{\partial x_1} = 4x_1^3 - 2x_1x_2 - x_3^2$$

$$\frac{\partial f}{\partial x_2} = 6x_2^2 - x_1^2 - 4x_3$$

$$\frac{\partial f}{\partial x_3} = 6x_3 + 4x_2 - 2x_1x_3$$

$$\text{所以 } \nabla f(x) = \begin{bmatrix} 4x_1^3 - 2x_1x_2 - x_3^2 \\ 6x_2^2 - x_1^2 - 4x_3 \\ 6x_3 + 4x_2 - 2x_1x_3 \end{bmatrix}$$





## 例题

求目标函数 $f(x)=x_1^4+2x_2^3+3x_3^2-x_1^2x_2+4x_2x_3-x_1x_3^2$ 的梯度和Hesse矩阵

解：

$$\frac{\partial^2 f}{\partial x_1^2} = 12x_1^2 - 2x_2, \frac{\partial^2 f}{\partial x_1 x_2} = -2x_1, \frac{\partial^2 f}{\partial x_1 x_3} = -2x_3$$

$$\frac{\partial f}{\partial x_2^2} = 12x_2, \frac{\partial^2 f}{\partial x_2 x_3} = 4, \frac{\partial^2 f}{\partial x_3^2} = 6 - 2x_1$$

$$\text{所以 } \nabla^2 f(x) = \begin{bmatrix} 12x_1^2 - 2x_2 & -2x_1 & -2x_3 \\ -2x_1 & 12x_2 & 4 \\ -2x_3 & 4 & 6 - 2x_1 \end{bmatrix}$$







## 泰勒展开

二阶泰勒展开式：

设函数  $f: R^n \rightarrow R$  具有二阶连续偏导数，则

$$f(X + p) = f(X) + \nabla f(X)^T p + \frac{1}{2} p^T \nabla^2 f(X) p + o(\|p\|^2)$$


其中  $o(\|p\|^2)$  当  $\|p\|^2 \rightarrow 0$  时，是关于  $\|p\|^2$  的高阶无穷小量。








## 泰勒展开举例






## 泰勒展开举例





## 泰勒展开举例





## 证明：梯度方向是函数的最速上升方向

证明：设函数  $f: R^n \rightarrow R$  在  $x_0$  处连续可导，其任意方向导数

$$\frac{\partial f(x_0)}{\partial p} = \lim_{t \rightarrow 0^+} \frac{f(x_0 + te) - f(x_0)}{t}$$

可将论题等价于以下优化问题：

$$\begin{aligned} \max \quad & \frac{\partial f(x_0)}{\partial p} \\ \text{s.t.} \quad & \|p\| = 1 \end{aligned}$$





## 证明：梯度方向是函数的最速上升方向

证明：设函数  $f: R^n \rightarrow R$  在  $x_0$  处连续可导，其任意方向导数

$$\frac{\partial f(x_0)}{\partial p} = \lim_{t \rightarrow 0^+} \frac{f(x_0 + te) - f(x_0)}{t}$$

(接上页)

对  $f(x_0 + te)$  在  $x_0$  处进行泰勒展开：

$$f(x_0 + te) = f(x_0) + \nabla f(x_0)^T te + \frac{t^2}{2} e^T \nabla^2 f(x_0)^T e + o(\|e\|^2)$$





## 证明：梯度方向是函数的最速上升方向

证明：设函数  $f: R^n \rightarrow R$  在  $x_0$  处连续可导，其任意方向导数

$$\frac{\partial f(x_0)}{\partial p} = \lim_{t \rightarrow 0^+} \frac{f(x_0 + te) - f(x_0)}{t}$$

(接上页)

将展开带入方向导数  $\frac{\partial f(x_0)}{\partial p}$  表达式：

$$\frac{f(x_0 + te) - f(x_0)}{t} = \nabla f(x_0)^T e + \frac{t}{2} e^T \nabla^2 f(x_0)^T e + o(\|e\|^2)$$

$$\lim_{t \rightarrow 0^+} \frac{f(x_0 + te) - f(x_0)}{t} = \nabla f(x_0)^T e = \nabla f(x_0)^T \frac{p}{\|p\|} = \nabla f(x_0)^T p$$





## 证明：梯度方向是函数的最速上升方向

证明：设函数 $f: R^n \rightarrow R$ 在 $x_0$ 处连续可导，其任意方向导数

$$\frac{\partial f(x_0)}{\partial p} = \lim_{t \rightarrow 0^+} \frac{f(x_0 + te) - f(x_0)}{t}$$

(接上页)

可以将优化问题等价写为：

$$\max \nabla f(x_0)^T p$$

$$s.t. \|p\| = 1$$





## 证明：梯度方向是函数的最速上升方向

证明：设函数  $f: R^n \rightarrow R$  在  $x_0$  处连续可导，其任意方向导数

$$\frac{\partial f(x_0)}{\partial p} = \lim_{t \rightarrow 0^+} \frac{f(x_0 + te) - f(x_0)}{t}$$

(接上页)

向量的内积可以写为如下形式：

$\|\nabla f(x_0)^T\| \|p\| \cos(\theta)$ , 其中  $\theta$  为  $\nabla f(x_0)^T$  与  $p$  的夹角

前两项为常数，优化问题的最大值在  $\cos(\theta)=1$  即  $\theta=0$  处取得

因此  $p = \frac{\nabla f(x_0)^T}{\|\nabla f(x_0)^T\|}$ , 为梯度方向。







西安电子科技大学  
XIDIAN UNIVERSITY

# 课后练习 Tutorial

## 课后练习 Tutorial #3

方向导数和梯度的课外阅读材料

<https://opentextbc.ca/calculusv3openstax/chapter/directional-derivatives-and-the-gradient/>



智能感知与图像理解教育部重点实验室  
KEY LABORATORY OF INTELLIGENT PERCEPTION  
AND IMAGE UNDERSTANDING OF MINISTRY OF EDUCATION



Y.Gu 16/10/2019



西安电子科技大学  
XIDIAN UNIVERSITY



IPIL  
智能感知与图像理解

谢谢！

