



西安电子科技大学
XIDIAN UNIVERSITY



IPIL
智能感知与图像理解

最优化理论

第五章：无约束最优化方法

人工智能学院
智能感知与图像理解教育部重点实验室



无约束最优化方法

1

坐标转换法

2

单形替换法

3

无约束优化算法总结





无约束最优化方法

1

坐标转换法

2

单形替换法

3

无约束优化算法总结





一、坐标轮换法简介

坐标轮换法也叫变量轮换法，是一种经典的直接优化法，由D'esopo于1959年提出，思想非常简单，将**多变量**的优化问题轮流地转化成**单变量**的优化问题，即依次沿各个**坐标方向**上作一维搜索，且每次搜索都以前一次搜索的最好点作为起点。






二、坐标轮换法基本原理

下面以二元函数为例来进行分析，然后给出n元函数的一般算法。

设某二元函数 $S = f(X) = f(x_1, x_2)$ ，其等高线见下图。设极值存在的区间为 $a_1 \leq x_1 \leq b_1$ ， $a_2 \leq x_2 \leq b_2$ ，其中 $e_1 = (1, 0)^T$ ， $e_2 = (0, 1)^T$ 分别表示 x_1 ， x_2 的坐标方向。





二、坐标轮换法基本原理

二元函数的搜索过程如下：

1. 设从 $X^{(0)} = (x_1^{(0)}, x_2^{(0)})$ 出发，先固定 $x_1 = x_1^{(0)}$ 不变，求以 x_2 为单变量的目标函数

$$f(x_2) = f(x_1^{(0)} + \lambda_2) = f(\lambda_2)$$

的极值，即利用一维搜索法求以 λ_2 为单变量的目标函数极值，从而可出最佳步长因子 λ_2^1 ，得

$$X^{(1)} = (x_1^{(0)}, x_2^{(0)} + \lambda_2^1)$$

$$S^{(1)} = f(X^{(1)})$$





二、坐标轮换法基本原理

二元函数的搜索过程如下：

2. 固定 $x_2 = x_2^{(1)} = x_2^{(0)} + \lambda_2^1$ 不变，求以 x_1 为单变量的目标函数 $f(x_1) = f(x_1^{(0)} + \lambda_1) = f(\lambda_1)$ 的极值，即求以 λ_1 为单变量的目标函数极值，从而可定出最佳步长 λ_1^1 ，得

$$X^{(2)} = (x_1^{(0)} + \lambda_1^1, x_2^{(0)} + \lambda_2^1) = f(x_1^{(1)}, x_2^{(1)}) \quad S^{(2)} = f(X^{(2)})$$

3. 因为 $S^{(2)}$ 优于 $S^{(1)}$ ，因此在下一轮坐标轮换搜索时搜索区间缩短为 $x_1^{(1)} \leq x_1 \leq b_1$ ， $x_2^{(1)} \leq x_2 \leq b_2$ 。在新的区间中重复以上步骤，每次搜索不仅可使目标函数值得到改善，而且可以将所搜区间进一步缩短，直到达到给定精度为止。





二、坐标轮换法基本原理

搜索方向与步长

n元函数的搜索过程如下：

给定初始点 x_0 , 从 x_0 出发, 依次沿坐标轴方向

进行最优一维搜索, 即 $e_i = (0, \dots, 0, 1, 0, \dots, 0)^T, i=1, 2, \dots, n$,
第 i 个分量

目标函数较复杂时,
最佳步长可用0.618
法或二次插值法

$$f(x_k^{i-1} + t_k^i e_i) = \min_t f(x_k^{i-1} + t e_i)$$
$$x_k^i = x_k^{i-1} + t_k^i e_i, \quad i = 1, \dots, n.$$

终止准则

设给定的允许误差 $\varepsilon > 0$, 若 $|X_k^n - X_{k-1}^n| \leq \varepsilon$, 则迭代终止, 输出
最优解 $X^* = X_k^n$

循环

否则令 $k=k+1$, 从点 x_k^n 出发, 再依次沿坐标轴方向 e_i 进行
最优一维搜索.





三、坐标轮换法算法步骤

- 已知目标函数 $f(X)$, 终止限 $\varepsilon > 0$.
- (1) 任选取始点 $X^{(0)}$ 作为第一轮循环的初始点 $\varepsilon > 0$.
- (2) 置搜索方向依次为
$$e_1 = [1, 0, 0, \dots, 0]^T$$
$$e_2 = [0, 1, 0, \dots, 0]^T$$
$$\dots$$
$$e_n = [0, 0, 0, \dots, 1]^T$$
- (3) 按下式求最优步长并进行迭代计算

$$f(X_k^{(i-1)} + t_k^{(i)} e_i) = \min_t f(X_k^{(i-1)} + t e_i)$$

$$X_k^{(i)} = X_k^{(i-1)} + t_k^{(i)} e_i$$





上式中, k 为循环次数, $k = 1, 2, \dots$; i 为该循环中一维搜索的序号, $i = 1, 2, \dots, n$; $t_k^{(i)}$ 为利用一维搜索求出的最优步长.

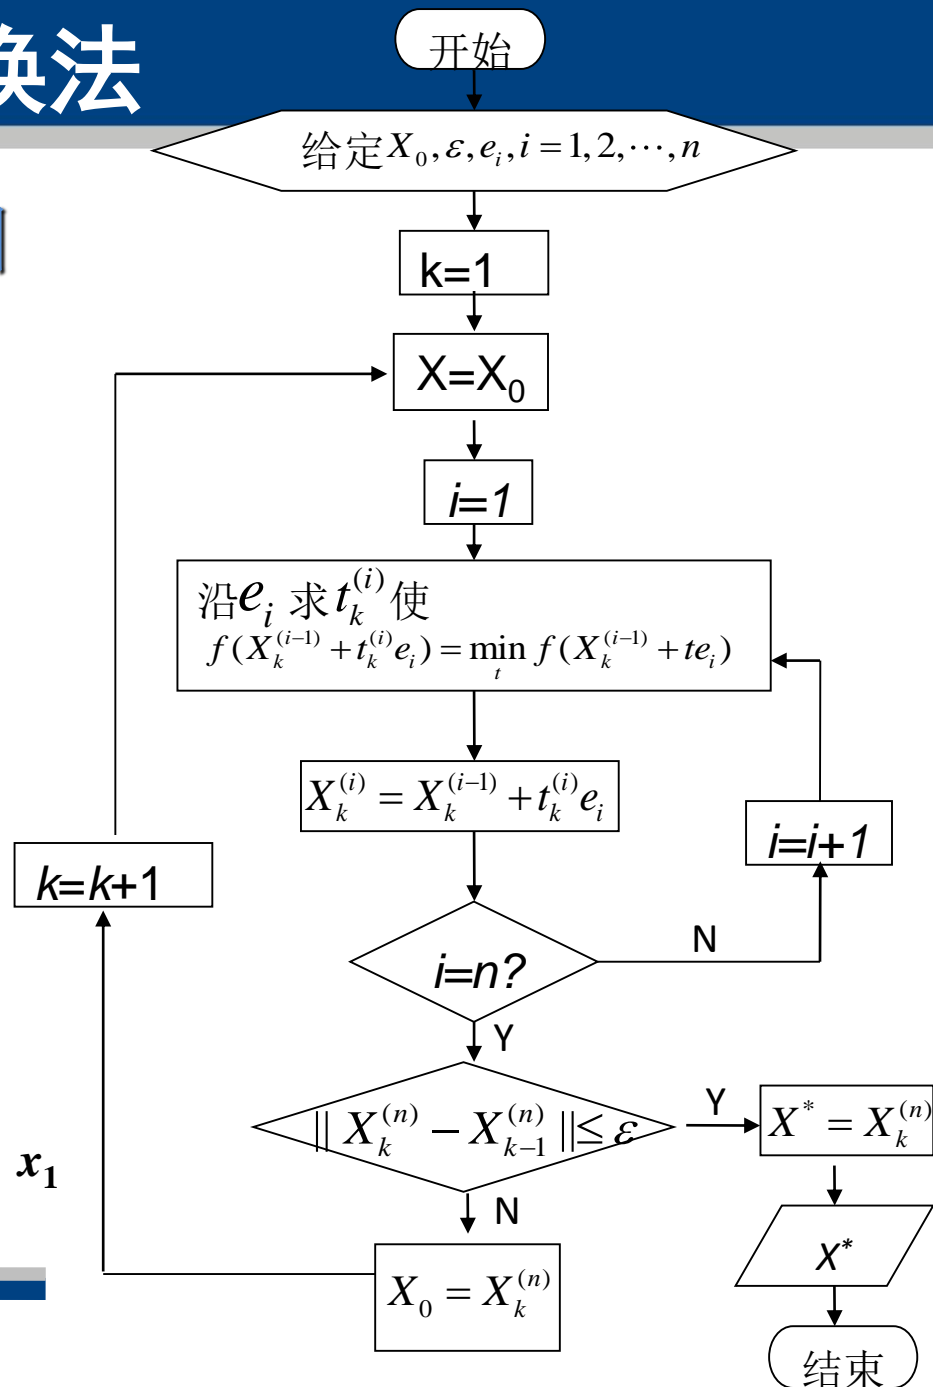

- (4) 如果 $i = n$, 即转 (5); 如果 $i < n$, 则转 (3).
- (5) 收敛性准则: $\|X_k^{(n)} - X_{k-1}^{(n)}\| \leq \varepsilon$, 若满足判别式, 即停止迭代, 输出最优解 $X^* = X_k^{(n)}$ 及 $f^* = f(X^*)$; 若不满足, 则令 $k = k + 1$, 转 (3).





坐标轮换法

四、坐标轮换法算法流程图





五、坐标轮换法实例

例1: 用坐标轮换法求 $\min f(X) = (x_1 - 2)^4 + (x_1 - 2x_2)^2$, 初始点 $X_0 = [0, 3]^T$, $\varepsilon = 0.04$.

解: 从初始点出发, 依次沿方向 $e_1 = (1, 0)^T$, $e_2 = (0, 1)^T$ 搜索, 以第一步为例, 从 X_0 出发, 沿 e_1 方向搜索, 求得 $X_1^{(1)}$ 点

$$f(X_0 + te_1) = [(x_0^{(1)} + te_1) - 2]^4 + [(x_0^{(1)} + te_1) - 2x_0^{(2)}]^2 = (t - 2)^4 + (t - 6)^2$$

$$\text{令 } \frac{d}{dt} f(X_0 + te_1) = 0, \text{ 即 } \frac{d}{dt} [(t - 2)^4 + (t - 6)^2] = 0$$

得 $t = 3.13$, 即取 $t_1^{(1)} = 3.13$. 于是有

$$X_1^{(1)} = X_0 + t_1^{(1)} e_1 = \begin{bmatrix} 0 \\ 3 \end{bmatrix} + 3.13 \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 3.13 \\ 3 \end{bmatrix}$$





五、坐标轮换法实例

例1：用坐标轮换法求 $\min f(X) = (x_1 - 2)^4 + (x_1 - 2x_2)^2$ ，初始点 $X_0 = [0, 3]^T$, $\varepsilon = 0.04$.

再从 $X_1^{(1)}$ 出发，沿方向 e_2 搜索，求得 $X_1^{(2)}$ 点

$$\begin{aligned} f(X_1^{(1)} + te_2) &= (x_1^{(1)} - 2)^4 + [x_1^{(1)} - 2(x_1^{(2)} + te_2)]^2 \\ &= 1.13^4 + [3.13 - 2 \times 3 - 2t]^2 \end{aligned}$$

$$\text{令 } \frac{d}{dt} f(X_1^{(1)} + te_2) = 0$$

可得 $t = -1.44$ ，即取 $t_1^{(2)} = -1.44$. 于是有

$$X_1^{(2)} = X_1^{(1)} + t_1^{(2)} e_2 = \begin{bmatrix} 3.13 \\ 3 \end{bmatrix} - 1.44 \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 3.13 \\ 1.56 \end{bmatrix}$$





五、坐标轮换法实例

例1：用坐标轮换法求 $\min f(X) = (x_1 - 2)^4 + (x_1 - 2x_2)^2$ ，初始点 $X_0 = [0, 3]^T$, $\varepsilon = 0.04$.

终止判别

$$\|X_1^{(2)} - X_0\| = \sqrt{(3.13 - 0)^2 + (1.56 - 3)^2} = 3.45 > \varepsilon$$

因终止条件不满足，需继续迭代，取 $X_0 = X_1^{(2)}$ ，进行第二轮循环迭代，各轮迭代计算数据见表1，最优化解为 $X^* = [2.22, 1.12]^T$.





五、坐标轮换法实例

例1：用坐标轮换法求 $\min f(X) = (x_1 - 2)^4 + (x_1 - 2x_2)^2$ ，初始点 $X_0 = [0, 3]^T$, $\varepsilon = 0.04$.

表1

循环迭代序号	X_0	$e_1 = [1, 0]^T$		$e_2 = [0, 1]^T$		$f(X_k^{(2)})$	$\ X_k^{(2)} - X_0\ $	是否满足收敛准则
		$t_k^{(1)}$	$X_k^{(1)}$	$t_k^{(2)}$	$X_k^{(2)}$			
1	0.00, 3.00	3.13	3.13, 1.56	1.44	3.13, 1.56	1.63	3.45	否
2	3.13, 1.56	-0.50	2.63, 1.56	-0.25	2.63, 1.31	0.16	0.56	否
3	2.63, 1.31	-0.19	2.44, 1.31	-0.09	2.44, 1.22	0.04	0.21	否
4	2.44, 1.22	-0.09	2.35, 1.22	-0.05	2.35, 1.17	0.015	0.10	否
5	2.35, 1.17	-0.06	2.29, 1.17	-0.03	2.29, 1.14	0.007	0.06	否
6	2.29, 1.14	-0.04	2.25, 1.14	-0.02	2.25, 1.12	0.004	0.045	否
7	2.25, 1.12	-0.03	2.22, 1.12	-0.01	2.22, 1.11	0.002	0.03	是





五、坐标轮换法有关说明

坐标轮换法的优点：算法简单，容易实现；

坐标轮换法的缺点：当维数增加时，效率明显下降，收敛慢，以振荡方式逼近最优解。只适用于变量数目少且目标函数中变量间的交互作用弱的情况。


注：若目标函数汇总没有自变量的乘积项，即一个变量的变化与其他变量无关，称之为无交互作用，这时该方法最有效。若目标函数中有自变量乘积项，则为弱交互作用，这时坐标轮换法的效率很低。





五、坐标轮换法有关说明

图(c) 目标函数中出现了脊线，称为强交互作用，此时如果某一步搜索正好落在脊线上，则无论向哪个方向搜索，目标函数值均增大，搜索过程终止于脊线上，坐标轮换法无效。



坐标轮换法受目标函数的形态影响很大

(a) 搜索有效，两次收敛； (b) 搜索低效； (c) 等值线出现脊线，搜索





无约束最优化方法

1

坐标转换法

2

单形替换法

3

无约束优化算法总结





一、单形替换法简介

单纯形替换法是Spendley、Hext 和Himsworth 于1962年提出；Nelder 和 Mead 1965年改进，也是一种不使用导数的求解无约束极小化问题的直接搜索方法，与前面几种方法不同的是，单纯形替换法不是利用搜索方向从一个点迭代到另一个更优的点，而是从一个单纯形迭代到另一个更优的单纯形。





二、单形替换法基本原理

- 现以求二元函数的极小点为例,说明单纯形法形成原理.
- 设二元函数 $f(X) = f(x_1, x_2)$ 在 $x_1 - x_2$ 平面上取不在同一条直线上的三个点 X_1, X_2, X_3 , 并以它们为顶点构成一单纯形——三角形. 算出各顶点的函数值 $f(X_1), f(X_2), f(X_3)$, 比较其大小, 现假定比较后有

$$f(X_1) > f(X_2) > f(X_3)$$

这说明点 X_1 最差, 点 X_3 最好, 点 X_2 次差.

- 为了寻找极小点, 一般来说应向最差点的反对称方向进行搜索.






单形替换法

- 以 x_4 记为 x_2x_3 的中点（如图所示），在 x_1x_4 的延长线上取点 x_5 ，使

$$x_5 = x_4 + (x_4 - x_1) = 2x_4 - x_1$$

x_5 称为 x_1 关于 x_4 的反射点。



- 算出 x_5 的函数值 $f(x_5)$ ，可能出现以下几种情形：





- (1) $f(X_5) < f(X_3)$


这说明搜索方向正确，可进一步扩大效果，继续沿 X_1X_5 向前搜索，也就是向前扩张。这时取

$$X_6 = X_4 + \alpha(X_4 - X_1)$$

其中 α 为扩张因子，一般取 $\alpha = 1.2 \sim 2.0$.

如果 $f(X_6) < f(X_5)$, 说明扩张有利，就可以点 X_6 代替点 X_1 构成新的单纯形 $\{X_2, X_3, X_6\}$.

如果 $f(X_6) > f(X_5)$, 说明扩张不利，舍去点 X_6 , 仍以点 X_5 代替 X_1 构成新的单纯形 $\{X_2, X_3, X_5\}$






单形替换法

- (2) $f(X_3) < f(X_5) < f(X_2)$

这说明搜索方向正确，但无须扩张，以 X_5 代替 X_1 构成新的单纯形 $\{X_2, X_3, X_5\}$.



- (3) $f(X_2) < f(X_5) < f(X_1)$

这表示 X_5 点走得太远，应缩回一些．若以 β 表示压缩因子，则有

$$X_7 = X_4 + \beta(X_5 - X_4) \quad (5.35)$$

β 常取为0.5.以 X_7 代替 X_1 构成新的单纯形 $\{X_2, X_3, X_7\}$.






- (4) $f(X_5) > f(X_1)$

这时应压缩更多一些，将新点压缩至 X_1 至 X_4 之间，令

$$X_8 = X_4 - \beta(X_4 - X_1) = X_4 + \beta(X_1 - X_4) \quad (5.36)$$


- 注意，将式 (5.35) 中的 X_5 代之以 X_1 ，即可得式 (5.36)。如果 $f(X_8) < f(X_1)$ ，则以 X_8 代替 X_1 构成新的单纯形 $\{X_2, X_3, X_8\}$ ，否则认为 X_1X_4 方向上所有点的函数值 $f(X)$ 都大于 $f(X_1)$ ，不能沿此方向搜索。





单形替换法

- 这时，可以以 X_3 为中心进行缩边。
若使顶点 X_1 和 X_2 向 X_3 移近一半距离，
得新单纯形 $\{X_3, X_9, X_{10}\}$ ，以此单纯形
为基础再进行寻优。





- 以上说明，不管哪种情况，我们都可以得到一个新的单纯形，其中至少有一顶点的函数值比原单纯形更小。如此继续，直至满足收敛终止准则。
- 在 n 维情况下，一个单纯形含有 $n+1$ 个顶点，计算工作量较大，但原理和上述二维情况相同。





三、单纯形法迭代步骤

- 已知设 X 为 n 维变量, 目标函数为 $f(X)$, 终止限为 $\varepsilon_1 > 0, \varepsilon_2 > 0$

- (1) 构成初始单纯形

在 n 维空间中选初始点 X_0 (离最优点越近越好), 从 X_0 出发, 沿各坐标方向以步长 t 得 n 个顶点 $X_i (i = 1, 2, \dots, n)$.

这样选择顶点可保证向量组 $X_1 - X_0, X_2 - X_0, \dots, X_n - X_0$ 线性无关. 否则, 就会使搜索范围局限在较低维的空间内, 有可能找不到极小点. 当然, 在各坐标方向可以走不同的距离.

- 步长 t 的范围可取 $0.5 \sim 15.0$, 开始时常取 $t = 1.5 \sim 2.0$, 接近最优点时要减小, 例如取 $0.5 \sim 1.0$.





- (2) 计算各顶点的函数值

$$y_i = f(X_i), \quad i = 0, 1, 2, \dots, n$$

比较各函数值的大小，确定最好点 X_L 、最差点 X_H 和次差点 X_G ，即

$$y_L = f(X_L) = \min_i y_i, \quad i = 0, 1, 2, \dots, n$$

$$y_H = f(X_H) = \max_i y_i, \quad i = 0, 1, 2, \dots, n$$

$$y_G = f(X_G) = \max_i y_i, \quad i = 0, 1, 2, \dots, H-1, H+1, \dots, n$$





•(3) 计算 X_H 之外各点的“重心” X_{n+1} ,

$$X_{n+1} = \frac{1}{n} \sum_{i=0, i \neq H}^n X_i$$


求出反射点

$$X_{n+2} = 2X_{n+1} - X_H$$

•(4) 当 $f(X_{n+2}) < f(X_L)$ 时, 需要扩张, 令

$$X_{n+3} = X_{n+1} + \alpha(X_{n+2} - X_{n-1})$$

如果 $f(X_{n+3}) < f(X_{n+2})$, 则以 x_{n+3} 代替 x_H 形成一新单纯形; 否则, 以代 x_{n+2} 替 x_H 构成新单纯形. 然后转 (8) .





•(5) 当 $f(X_L) \leq f(X_{n+2}) < f(X_G)$ 时, 以 X_{n+2} 代替 X_H 构成新单纯形, 然后转(8).

• (6) 当 $f(X_G) \leq f(X_{n+2}) < f(X_H)$ 时, 则需要收缩. 即令

$$X_{n+4} = X_{n+1} + \beta(X_{n+2} - X_{n+1}) \quad (5.37)$$

以 X_{n+4} 代替 X_H 得新单纯形, 并转(8).

•(7) 当 $f(X_{n+2}) \geq f(X_H)$ 时, 令

$$X_{n+5} = X_{n+1} + \beta(X_H - X_{n+1})$$

如果 $f(X_{n+5}) \geq f(X_H)$, 则将单纯形缩边, 可将向量 $X_i - X_L$ 的长度缩小一半, 即

$$X_i = X_L + \frac{1}{2}(X_i - X_L) = \frac{1}{2}(X_i + X_L), \quad i = 0, 1, 2, \dots, n, \quad i \neq L.$$

这样可得一新单纯形. 否则就以 X_{n+5} 代替 X_H 得新单纯形. 然后转(8).





- (8) 收敛性检验，每次迭代得到新单纯形后，即应进行收敛性检验，如满足收敛指标，则迭代停止， X_L 即为所求的近似解。否则，继续进行迭代计算。通常所用的收敛准则是

$$\sum_{i=0, i \neq L}^n [f(X_i) - f(X_L)]^2 \leq \varepsilon_1$$

或

$$\left| \frac{f(X_H) - f(X_L)}{f(X_L)} \right| \leq \varepsilon_2$$

式中 ε_1 和 ε_2 为预先给定的允许误差。





四、单形替换法实例

例3. 试用单形替换法求 $f(\mathbf{X}) = 4(x_1 - 5)^2 + (x_2 - 6)^2$ 的极小值。

解： 选 $\mathbf{X}_0 = [8, 9]^T$, 并取 $\mathbf{X}_1 = [10, 11]^T$, $\mathbf{X}_2 = [8, 11]^T$. 这三点不在一条直线上, 用它们作为初始单纯形的顶点, 如下图所示。然后计算各定点的函数值:

$f(\mathbf{X}_0) = 45$, $f(\mathbf{X}_1) = 125$, $f(\mathbf{X}_2) = 65$, 可知 \mathbf{X}_1 为最差点, \mathbf{X}_0 为最好点。

以 \mathbf{X}_3 表示 \mathbf{X}_0 和 \mathbf{X}_2 的重心, 则

$$\mathbf{X}_3 = \frac{1}{n} \left(\sum_{i=0, i \neq H}^n \mathbf{X}_i \right) = \frac{1}{2} \left(\begin{bmatrix} 8 \\ 9 \end{bmatrix} + \begin{bmatrix} 8 \\ 11 \end{bmatrix} \right) = \begin{bmatrix} 8 \\ 10 \end{bmatrix}$$

反射点

$$\mathbf{X}_4 = 2\mathbf{X}_3 - \mathbf{X}_1 = 2 \begin{bmatrix} 8 \\ 10 \end{bmatrix} - \begin{bmatrix} 10 \\ 11 \end{bmatrix} = \begin{bmatrix} 6 \\ 9 \end{bmatrix}$$

$$f(\mathbf{X}_4) = 4(6 - 5)^2 + (9 - 6)^2 = 13$$





例3. 试用单形替换法求 $f(\mathbf{X}) = 4(x_1 - 5)^2 + (x_2 - 6)^2$ 的极小值。

由于 $f(\mathbf{X}_4) < f(\mathbf{X}_0)$ ，故需扩张，取 $\alpha=2$ ，则

$$\mathbf{X}_5 = \mathbf{X}_3 + 2(\mathbf{X}_4 - \mathbf{X}_3) = \begin{bmatrix} 8 \\ 10 \end{bmatrix} + 2\left(\begin{bmatrix} 6 \\ 9 \end{bmatrix} - \begin{bmatrix} 8 \\ 10 \end{bmatrix}\right) = \begin{bmatrix} 4 \\ 8 \end{bmatrix}$$


$$f(\mathbf{X}_5) = 4(4 - 5)^2 + (8 - 6)^2 = 8$$

因为 $f(\mathbf{X}_5) < f(\mathbf{X}_4)$ ，故以 \mathbf{X}_5 代替 \mathbf{X}_1 ，由 \mathbf{X}_5 ， \mathbf{X}_0 和 \mathbf{X}_2 构成新单纯形，然后进行下一轮循环。该问题得最优解为 $\mathbf{X}^* = [5, 6]^T$ ， $f(\mathbf{X}^*) = 0$ 。经32次循环，可把目标函数 $f(\mathbf{X})$ 减少到 1×10^{-6} 。下图给出了前几次迭代得情形。





单形替换法





• 五、单纯形法有关说明

本算法上机占用内存很少，对变量不多且精度要求不高的问题此法很方便，但当变量个数多于10以上，此法就显得不十分有效。





无约束最优化方法

1

坐标转换法

2

单形替换法

3

无约束优化算法总结





无约束优化方法——间接法总结

1、梯度法

方向 负梯度 用到一阶导数

适合于精度不高或用于复杂函数寻找一个好的初始点

2、牛顿法

用到一阶导数和Hesse矩阵，具有二次收敛性

要求Hesse矩阵非奇异，且维数不宜太高

3、共轭梯度法

用到一阶导数，具有二次收敛性

4、变尺度法

收敛快，效果好，被认为是目前最有效的无约束优化方法。适用于维数较高，具有一阶偏导数的目标函数





无约束优化方法——直接法总结

1、坐标轮换法

计算效率较低

适合维数较低，目标函数无导数或导数较难求

2、单形替换法

算法直观，收敛慢





第四次作业:

习题五 (P119)

第7, 8题





西安电子科技大学
XIDIAN UNIVERSITY



IPIL
智能感知与图像理解

Key Laboratory of Intelligent Perception and Image Understanding of Ministry of Education

THE END

Thanks for your participation!